



# Naïve Bayesian Learning

---

Marcílo Souto  
DIMAp/UFRN

# Teorema de Bayes

- Probabilidade de um evento  $H$  dada evidência  $E$ :

$$\Pr[H | E] = \frac{\Pr[E | H] \Pr[H]}{\Pr[E]}$$

- Probabilidade a *priori* de  $H$ :  $\Pr[H]$ 
  - Probabilidade do evento *antes* da evidência ser vista
- Probabilidade a *posteriori*  $H$ :  $\Pr[H | E]$ 
  - Probabilidade do evento *ápos* a evidência é vista

# Aplicação do Teorema de Bayes: Diagnóstico Médico



•Seja

M=doença  
meningite

S= dor no pescoço

•Um Médico sabe:

$$\Pr(S/M)=0.5$$

$$\Pr(M)=1/50000$$

$$\Pr(S)=1/20$$



$$\Pr(M/S)=\frac{\Pr(S/M)\Pr(M)}{\Pr(S)}$$

$$= \frac{0,5 * (1/50000)}{1/20} = 0,002$$

•A probabilidade de uma pessoa ter meningite dado que ela está com dor no pescoço é 0,02% ou ainda 1 em 5000.

# Naïve Bayes para classificação

- Aprendizado: qual a probabilidade da classe dada uma instância?
  - Evidência  $E$  = uma instância (padrão)
  - Evento  $H$  = valor da classe para a instância (Play=yes, Play=no)
- Suposição Naïve Bayes: evidência pode ser dividida em partes independentes (i.e., os atributos das instâncias são independentes)

$$\Pr[H | E] = \frac{\Pr[E_1 | H] \Pr[E_2 | H] \dots \Pr[E_n | H] \Pr[H]}{\Pr[E]}$$

# Conjunto de Dados "Tempo"

D1  
D2  
D3  
D4  
D5  
D6  
D7  
D8  
D9  
D10  
D11  
D12  
D13  
D14

| Outlook  | Temperature | Humidity | Windy | Play |
|----------|-------------|----------|-------|------|
| overcast | cool        | normal   | true  | yes  |
| overcast | hot         | high     | false | yes  |
| overcast | hot         | normal   | false | yes  |
| overcast | mild        | high     | true  | yes  |
| rainy    | cool        | normal   | false | yes  |
| rainy    | mild        | high     | false | yes  |
| rainy    | mild        | normal   | false | yes  |
| sunny    | cool        | normal   | false | yes  |
| sunny    | mild        | normal   | true  | yes  |
| rainy    | cool        | normal   | true  | no   |
| rainy    | mild        | high     | true  | no   |
| sunny    | hot         | high     | false | no   |
| sunny    | hot         | high     | true  | no   |
| sunny    | mild        | high     | false | no   |

## Exemplo para o conjunto de dados de Tempo

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| Sunny   | Cool  | High     | True  | ?    |

← *Evidência E*

$$\Pr[\text{yes} \mid E] = \Pr[\text{Outlook} = \text{Sunny} \mid \text{yes}] \times$$

$$\Pr[\text{Temperature} = \text{Cool} \mid \text{yes}] \times$$

$$\Pr[\text{Humidity} = \text{High} \mid \text{yes}] \times$$

$$\Pr[\text{Windy} = \text{True} \mid \text{yes}] \times \frac{\Pr[\text{yes}]}{\Pr[E]}$$

↖  
*Probabilidade para  
classe “yes”*

# Probabilidades para o Conjunto

| Outlook  |     | Temperature |      |     |     | Humidity |     | Windy |       | Play |     |      |      |
|----------|-----|-------------|------|-----|-----|----------|-----|-------|-------|------|-----|------|------|
|          | Yes | No          |      | Yes | No  |          | Yes | No    |       | Yes  | No  | Yes  | No   |
| Sunny    | 2   | 3           | Hot  | 2   | 2   | High     | 3   | 4     | False | 6    | 2   | 9    | 5    |
| Overcast | 4   | 0           | Mild | 4   | 2   | Normal   | 6   | 1     | True  | 3    | 3   |      |      |
| Rainy    | 3   | 2           | Cool | 3   | 1   |          |     |       |       |      |     |      |      |
| Sunny    | 2/9 | 3/5         | Hot  | 2/9 | 2/5 | High     | 3/9 | 4/5   | False | 6/9  | 2/5 | 9/14 | 5/14 |
| Overcast | 4/9 | 0/5         | Mild | 4/9 | 2/5 | Normal   | 6/9 | 1/5   | True  | 3/9  | 3/5 |      |      |
| Rainy    | 3/9 | 2/5         | Cool | 3/9 | 1/5 |          |     |       |       |      |     |      |      |

## ■ Um dia novo:

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| Sunny   | Cool  | High     | True  | ?    |

Likelihood of the two classes

For "yes" =  $2/9 \times 3/9 \times 3/9 \times 3/9 \times 9/14 = 0.0053$

For "no" =  $3/5 \times 1/5 \times 4/5 \times 3/5 \times 5/14 = 0.0206$


Conversion into a probability by normalization:

$P(\text{"yes"}) = 0.0053 / (0.0053 + 0.0206) = 0.205$

$P(\text{"no"}) = 0.0206 / (0.0053 + 0.0206) = 0.795$

## Por que Naïve?

- Suponha que todos os atributos são independentes, dada a classe
- O que isso significa?



$$\Pr(\text{outlook}=\text{sunny} \mid \text{windy}=\text{true}, \text{play}=\text{yes}) = \Pr(\text{outlook}=\text{sunny} \mid \text{play}=\text{yes})$$



# Conjunto de Dados "Tempo"

| Outlook  | Windy | Play |
|----------|-------|------|
| overcast | FALSE | yes  |
| rainy    | FALSE | yes  |
| rainy    | FALSE | yes  |
| overcast | TRUE  | yes  |
| sunny    | FALSE | yes  |
| rainy    | FALSE | yes  |
| sunny    | TRUE  | yes  |
| overcast | TRUE  | yes  |
| overcast | FALSE | yes  |

# A suposição é satisfeita?

- #yes=9
- #sunny=2
- #windy, yes=3
- #sunny|windy, yes=1

$\Pr(\text{outlook}=\text{sunny}|\text{windy}=\text{true}, \text{play}=\text{yes})=1/3$

$\Pr(\text{outlook}=\text{sunny}|\text{play}=\text{yes})=\mathbf{2/9}$

$\Pr(\text{windy}|\text{outlook}=\text{sunny}, \text{play}=\text{yes})=1/2$

$\Pr(\text{windy}|\text{play}=\text{yes})=3/9$

Assim, a suposição NÃO é satisfeita.

| Outlook  | Windy | Play |
|----------|-------|------|
| overcast | FALSE | yes  |
| rainy    | FALSE | yes  |
| rainy    | FALSE | yes  |
| overcast | TRUE  | yes  |
| sunny    | FALSE | yes  |
| rainy    | FALSE | yes  |
| sunny    | TRUE  | yes  |
| overcast | TRUE  | yes  |
| overcast | FALSE | yes  |

## O problema de “frequência-zero”

- E se um valor de atributo não ocorre para cada valor da classe (e.g., “Humidity = high” para a classe “yes”)?
  - Probabilidade será zero!
  - Probabilidade a *posteriori* probability também será zero!  
(Não importa os valores dos outros atributos!)
- Solução: adicione 1 ao contador de cada valor de atributo para cada combinação de classe (*Laplace estimator*)
- Resultado: probabilidades nunca serão zero

$$\Pr[\textit{Humidity} = \textit{High} \mid \textit{yes}] = 0$$

$$\Pr[\textit{yes} \mid E] = 0$$

## Estimativas modificadas de probabilidade

- Em alguns casos a adição de uma constante diferente de zero pode ser apropriada
- Exemplo: atributo *outlook* para a classe *yes*

$$\frac{2 + \mu/3}{9 + \mu}$$

*Sunny*

$$\frac{4 + \mu/3}{9 + \mu}$$

*Overcast*

$$\frac{3 + \mu/3}{9 + \mu}$$

*Rainy*

# Valores faltosos

- Treinamento: instância não é incluída na frequência do contador
- Classificação: atributo será omitido do cálculo
- Exemplo:

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| ?       | Cool  | High     | True  | ?    |

Likelihood of "yes" =  $3/9 \times 3/9 \times 3/9 \times 9/14 = 0.0238$

Likelihood of "no" =  $1/5 \times 4/5 \times 3/5 \times 5/14 = 0.0343$

$P(\text{"yes"}) = 0.0238 / (0.0238 + 0.0343) = 41\%$

$P(\text{"no"}) = 0.0343 / (0.0238 + 0.0343) = 59\%$

# Atributos numéricos?

- Suposição usual: os valores dos atributos têm uma *distribuição normal ou Gaussiana* (dada a classe)
- A *função de densidade probabilidade* para a distribuição normal é definida por dois parâmetros:

- Média da amostra  $\mu$ :

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

- Desvio padrão  $\sigma$ :

$$\sigma = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

- Função de densidade  $f(x)$ :

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

# Estatísticas para a base Tempo

| Outlook  |            |           | Temperature    |            | Humidity  |                | Windy      |           | Play  |            |           |      |      |
|----------|------------|-----------|----------------|------------|-----------|----------------|------------|-----------|-------|------------|-----------|------|------|
|          | <i>Yes</i> | <i>No</i> |                | <i>Yes</i> | <i>No</i> |                | <i>Yes</i> | <i>No</i> |       | <i>Yes</i> | <i>No</i> |      |      |
| Sunny    | 2          | 3         |                | 83         | 85        |                | 86         | 85        | False | 6          | 2         | 9    | 5    |
| Overcast | 4          | 0         |                | 70         | 80        |                | 96         | 90        | True  | 3          | 3         |      |      |
| Rainy    | 3          | 2         |                | 68         | 65        |                | 80         | 70        |       |            |           |      |      |
|          |            |           |                | ...        | ...       |                | ...        | ...       |       |            |           |      |      |
| Sunny    | 2/9        | 3/5       | <i>mean</i>    | 73         | 74.6      | <i>mean</i>    | 79.1       | 86.2      | False | 6/9        | 2/5       | 9/14 | 5/14 |
| Overcast | 4/9        | 0/5       | <i>std dev</i> | 6.2        | 7.9       | <i>std dev</i> | 10.2       | 9.7       | True  | 3/9        | 3/5       |      |      |
| Rainy    | 3/9        | 2/5       |                |            |           |                |            |           |       |            |           |      |      |

## ■ Exemplo:

$$f(\text{temperature} = 66 \mid \text{yes}) = \frac{1}{\sqrt{2\pi}6.2} e^{-\frac{(66-73)^2}{2*6.2^2}} = 0.0340$$

# Classificando um novo dia

- Novo dia:

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| Sunny   | 66    | 90       | true  | ?    |

Likelihood of "yes" =  $2/9 \times 0.0340 \times 0.0221 \times 3/9 \times 9/14 = 0.000036$

Likelihood of "no" =  $3/5 \times 0.0291 \times 0.0380 \times 3/5 \times 5/14 = 0.000136$

$P(\text{"yes"}) = 0.000036 / (0.000036 + 0.000136) = 20.9\%$

$P(\text{"no"}) = 0.000136 / (0.000036 + 0.000136) = 79.1\%$

- Valores faltosos durante treinamento: não são incluídos no cálculo da média e do desvio padrão



# Observações

- ✉ Junto com árvores de decisão, redes neurais, vizinhos mais-próximos, é um dos métodos de aprendizagem mais práticos
- ✉ Quando usa-lo
  - ✉ Quando se tem disponível um conjunto de treinamento médio ou grande
  - ✉ Os atributos que descrevem as instâncias forem condicionalmente independentes dada uma classificação
  - ✉ Note também que nem todos os atributos numéricos vão obedecer uma distribuição normal
- ✉ Aplicações:
  - ✉ Diagnóstico
  - ✉ Classificação de documentos (texto)